

Canevas méthodologique – Analyse et prédiction de la variabilité photovoltaïque

Ce document fournit une piste de modélisation claire, progressive et physiquement motivée pour le projet : **Analyse et prédiction de la variabilité de la production solaire en région PACA**. L'objectif n'est **pas** de prédire la production photovoltaïque, mais de **quantifier et anticiper sa variabilité**, car à priori c'est elle qui pose un problème opérationnel au réseau électrique (à confirmer et voir si vous êtes en phase avec cela).

1. Problème traité (clarification essentielle)

La production photovoltaïque n'est pas problématique en soi lorsqu'elle est stable. Les difficultés réseau apparaissent lorsque la production **varie rapidement dans le temps** (passages nuageux, lever/coucher du soleil, fronts météorologiques).

👉 Le projet pourrait donc viser à :

- mesurer la **variabilité temporelle** de la production PV (objectif de l'exploration),
- comprendre ses **facteurs physiques et météorologiques (objectif de l'exploration)**,
- **prédire** les épisodes de forte variabilité à court terme (30 min à 2 h).

2. Données et harmonisation

Sources :

- Les données que vous avez retenues

Prétraitements imposés :

- Pas de temps commun : par exemple **30 minutes**
- Alignement temporel strict (UTC ou heure locale cohérente)
- Zone géographique déjà sélectionnée : **région PACA uniquement**
- Suppression des périodes nocturnes si nécessaire (production nulle structurelle) —> déjà en cours de réalisation

3. Définition de la variable cible (étape clé)

La variable cible pourrait représenter la **variabilité de la production**, et non la production elle-même.

Cette distinction est essentielle car :

- la production photovoltaïque est largement déterminée par des effets géométriques prévisibles (heure de la journée, saison),
- un modèle de production peut obtenir de bons scores tout en lissant les variations rapides,
- ce sont les changements brusques de production (rampes) qui posent un problème opérationnel au réseau,

- prédire la variabilité permet de cibler directement les situations à risque (passages nuageux, transitions jour/nuit),
- la variabilité ne se déduit pas de manière fiable d'une simple prédiction de la production.

Définition recommandée

Variabilité normalisée à 30 minutes :

$$V(t) = |P(t) - P(t-1)| / P_{\text{capacité}}$$

Cette formulation est recommandée car :

- elle mesure directement les **rampes de puissance**, qui sont la source principale de stress pour le réseau,
- la normalisation par la capacité installée rend l'indicateur **indépendant de la taille du parc**,
- elle permet de **comparer différentes périodes** (saisons, années) malgré l'évolution du parc PV,
- elle est **robuste aux biais de niveau** (été vs hiver, midi vs matin/soir),
- elle est simple à interpréter : une valeur élevée signifie une variation rapide relative de la production,
- elle est cohérente avec les indicateurs de variabilité utilisés dans la littérature énergie et réseau.

avec :

- $P(t)$: production PV régionale (MW)
- $P_{\text{capacité}}$: capacité installée totale (MW)

Cette définition permet donc :

- la comparaison entre saisons et années,
- une interprétation directe en termes de stress réseau.

4. Prétraitement temporel et découpage des données (obligatoire)

Cette étape est **structurante** : une mauvaise préparation temporelle invalide toute la modélisation, même avec un bon modèle.

4.1 Traitements temporels à appliquer

Les traitements suivants doivent être appliqués **explicitement et systématiquement** :

- **Resampling** de toutes les séries sur un pas commun (ex. 30 minutes)
 - agrégation par moyenne ou somme selon la variable (production → moyenne ou somme cohérente, météo → moyenne)
- **Alignement temporel strict** entre production et météo
 - même horodatage exact
 - pas de décalage implicite
- **Gestion des valeurs manquantes**
 - interpolation courte autorisée pour la météo si nécessaire
 - pas d'interpolation de la production sur de longues durées

- **Filtrage optionnel des périodes nocturnes**
 - production structurellement nulle
 - permet de se concentrer sur la variabilité pertinente
- **Création des variables dérivées**
 - $\Delta P(t) = P(t) - P(t-1)$
 - $\Delta GHI(t) = GHI(t) - GHI(t-1)$
 - indicateurs temporels (heure, jour)

4.2 Encodage temporel recommandé

Pour les variables temporelles cycliques :

- heure du jour → encodage sin / cos
- jour de l'année → encodage sin / cos

Ces encodages permettent :

- de respecter la continuité physique du temps,
- d'éviter des discontinuités artificielles (ex. 23h → 0h),
- d'améliorer la généralisation des modèles.

4.3 Exemple de jeu de données après prétraitement

datetime	P_MW	GHI	cloud	ΔP	ΔGHI	sin_hour	cos_hour	sin_doy	cos_doy	V(t)
2022-06-15 10:00	420	650	0.2	+15	+40	0.50	-0.86	0.98	-0.18	0.003
2022-06-15 10:30	435	690	0.1	+15	+40	0.61	-0.79	0.98	-0.18	0.003
2022-06-15 11:00	410	620	0.5	-25	-70	0.71	-0.70	0.98	-0.18	0.005

Ce tableau illustre :

- l'alignement production / météo,
- les variations temporelles explicites,
- la variable cible V(t) calculée après normalisation.

4.4 Découpage temporel des données

Aucun mélange temporel n'est autorisé.

Découpage recommandé :

- **Train** : premières années disponibles
- **Validation** : année suivante
- **Test** : dernières années

Exemple :

- Train : 2019–2021
- Validation : 2022
- Test : 2023–2024

Ce découpage garantit :

- l'absence de fuite temporelle,

- l'évaluation sur des régimes météorologiques différents,
- une comparaison honnête entre baseline physique et modèles ML.

5. Baseline physique (référence littérature)

Avant tout modèle de machine learning, une **baseline physiquement justifiée** doit être construite.

Hypothèse physique minimale

La production photovoltaïque est proportionnelle à l'irradiance :

$$P(t) \approx C \times \eta \times \text{GHI}(t) \longrightarrow (\text{à vérifier})$$

Cette formulation est issue de la modélisation physique standard des systèmes photovoltaïques et repose sur les principes suivants :

- la puissance produite est proportionnelle au **flux radiatif incident** sur les panneaux (irradiance globale),
- la capacité installée agrège la surface active totale des modules,
- le rendement moyen η capture les effets technologiques (conversion, pertes), supposés constants à l'échelle régionale.

Elle est couramment utilisée comme approximation de premier ordre dans la littérature énergie et solaire, notamment dans les travaux de référence suivants :

- Duffie & Beckman, *Solar Engineering of Thermal Processes* (modélisation physique de la conversion solaire),
- Perez et al., *Modeling daylight availability and irradiance components*, Solar Energy,
- Fraunhofer ISE (2022), *Residual Load Variability Analysis* (usage de relations irradiance $\rightarrow$ production à l'échelle agrégée),
- Cramer et al. (2022), *Weather forecast precision and intraday volatility* (lien entre variations d'irradiance et volatilité intraday).

Dans ce projet, cette relation n'est **pas** utilisée pour prédire directement la production. Elle est introduite comme **point de départ physique** afin de structurer l'étude et la modélisation de la variabilité.

Commencer par cette relation permet en effet :

- de **justifier scientifiquement la variable cible** : la variabilité de production découle mécaniquement des variations d'irradiance,
- de **motiver la modélisation de $\Delta P(t)$** plutôt que de $P(t)$, en cohérence avec le problème réseau,
- de construire une **baseline physique simple et interprétable** avant tout machine learning,
- de fournir un **référentiel de comparaison** pour évaluer la réelle valeur ajoutée des modèles ML,
- d'éviter une modélisation purement empirique déconnectée des mécanismes physiques sous-jacents.

Ainsi, on ne cherche pas à modéliser $P(t)$, mais directement $\Delta P(t)$, ce qui conduit naturellement à une modélisation dédiée de la variabilité.

En conséquence, la variabilité de production est liée à la **variation d'irradiance**.

Baseline physique recommandée

$$V_{\text{phys}}(t) = \alpha \times |\Delta \text{GHI}(t)|$$

avec :

- $\Delta \text{GHI}(t) = \text{GHI}(t) - \text{GHI}(t-1)$
- α estimé par régression linéaire

Cette baseline est :

- simple,
- interprétable,
- issue directement de la physique du photovoltaïque.

Elle sert de **référence minimale** : tout modèle plus complexe doit faire mieux.

6. Enrichissement météo (baseline métier)

On enrichit la baseline physique avec des variables explicatives cohérentes :

Variables possibles :

- $\Delta \text{GHI}(t)$
- nébulosité et Δ nébulosité
- température
- heure du jour (sin, cos)
- jour de l'année (sin, cos)

Forme générale :

$$V(t) = f(\Delta \text{GHI}, \text{nuages}, \text{temps})$$

Implémentation attendue :

- régression linéaire multiple ou GAM

7. Modèle de machine learning (baseline ML)

Un nombre limité de modèles ML est attendu (2 à 3 maximum). L'objectif n'est pas d'optimiser exhaustivement les performances, mais de comparer des approches représentatives et de comprendre leur comportement par rapport à la baseline physique.

Choix recommandé :

- Gradient Boosting (XGBoost / LightGBM)
- ou
- Random Forest

Variables d'entrée

Les variables d'entrée doivent permettre au modèle d'anticiper **les changements rapides** de production, et non son niveau moyen.

Elles sont organisées par rôle explicatif :

- **Mémoire du système (lags de production)**
 - $P(t-1)$, $P(t-2)$
 - permettent de capter l'inertie du système et les rampes déjà engagées

- **Mémoire météorologique (lags météo)**
 - $GHI(t-1)$, $GHI(t-2)$
 - représentent l'évolution récente de l'irradiance, souvent plus informative que sa valeur instantanée
- **Signaux de changement (variations)**
 - ΔGHI , Δ nébulosité
 - capturent directement les passages nuageux rapides, principaux déclencheurs de forte variabilité
- **Contexte physique temporel**
 - heure du jour (sin, cos)
 - jour de l'année (sin, cos)
 - indiquent la position du soleil et la sensibilité du système aux perturbations météo

L'objectif n'est pas d'accumuler des features, mais de représenter :

- l'état récent du système,
- la dynamique météo,
- le contexte solaire.

Cible

La cible correspond à la **variabilité future**, pas à la production future.

- $V(t+1)$: variabilité à 30 minutes
 - horizon principal, directement exploitable opérationnellement
- optionnel : $V(t+2)$, $V(t+4)$
 - permet d'évaluer la dégradation des performances quand l'horizon augmente
 - met en évidence les limites de prévisibilité liées à la météo

Ce choix garantit que le modèle est évalué sur sa capacité à **anticiper les épisodes instables**, et non à lisser la production.

8. Évaluation des performances

Métriques principales :

- MAE ou RMSE sur $V(t)$

Métrique métier complémentaire :

- détection des fortes variabilités
- seuil = quantile 90 ou 95 de $V(t)$

Objectif :

- ne pas manquer les épisodes critiques,
- pas seulement optimiser l'erreur moyenne.

9. Interprétabilité (exigée)

Les résultats doivent inclure :

- importance des variables

- analyse qualitative des facteurs dominants

Attendu :

- rôle central de l'irradiance
- impact des passages nuageux
- effets des transitions jour/nuit

10. Message clé du projet

La variabilité photovoltaïque est un phénomène **physique avant d'être un problème de machine learning**.

Le rôle du data scientist est :

- de partir de la physique,
- de construire des indicateurs pertinents,
- puis d'évaluer si le machine learning apporte un gain réel et mesurable.